# BankInsight XAI

Classification explicable pour le marketing bancaire | ENSI - Data Mining 2026/2027

## Problème métier et données

Prioriser les contacts susceptibles de souscrire à un dépôt à terme (y = yes). UCI Bank Marketing : 45,211 observations, 11.7% de positifs. Décision juste avant l'appel planifié ; duration exclue car connue après l'appel. Jour, mois, canal et rang de campagne supposés connus. Les observations historiques ne mesurent pas un effet causal de campagne.

## Protocole reproductible

Séparation stratifiée 80/20, graine 42. Entraînement : 36,168 lignes (mode complet), test indépendant : 9,043. Imputation, one-hot et standardisation ajustées dans les plis ; recherche de 2 candidats, 3 plis, sélection par Average Precision (AP). Pondération des classes sauf KNN. Aucune optimisation sur le test ; seuil exploratoire de 0,50. Probabilités non calibrées.

Mode rapide (2 500 lignes) : Forêt aléatoire, AP test 0.398. Mode complet : XGBoost, AP test 0.446. Même holdout déjà consulté : comparaison descriptive, aucun réglage guidé par le test.

## Comparaison réelle - modèle recommandé : XGBoost

| Modèle | AP CV | AP test | ROC-AUC | Précision | Rappel | F1 |
|---|---|---|---|---|---|---|
| Régression logistique | 0.384 | 0.394 | 0.752 | 0.268 | 0.602 | 0.370 |
| Arbre de décision | 0.364 | 0.375 | 0.745 | 0.273 | 0.584 | 0.372 |
| K plus proches voisins | 0.297 | 0.321 | 0.694 | 0.524 | 0.206 | 0.296 |
| Forêt aléatoire | 0.400 | 0.410 | 0.765 | 0.324 | 0.578 | 0.416 |
| XGBoost | 0.427 | 0.446 | 0.787 | 0.337 | 0.621 | 0.437 |

## Explications SHAP et exemple individuel

Variables dominantes, moyenne |SHAP| en probabilité : month (0.059), housing (0.048), poutcome (0.046). SHAP permutation marginale, 24 clients du test, 20 références d'entraînement et 3 permutations. Erreur d'additivité maximale : 5.6e-17. Probabilité de souscription : 18.9%. Les principales associations locales sont : month (baisse de 6.6 points), housing (baisse de 4.3 points), loan (baisse de 3.0 points). Ces contributions décrivent le modèle et ne démontrent aucun effet causal.

## Regard critique : SHAP / LIME et équité

Même modèle, client et classe positive. Accord de signe sur les principaux facteurs SHAP : 100% ; fidélité locale LIME $R^2$ = 0.294. L'additivité SHAP est vérifiée pour les références échantillonnées ; LIME ajuste un substitut local sur 700 perturbations. Les voisinages et variables corrélées peuvent produire des divergences. Sur l'échantillon SHAP, moyenne |âge| = 0.028 et |situation familiale| = 0.027. Comparer les taux de ciblage et rappels par groupe (effectifs dans l'application), sans conclure à une certification d'équité. La faible fidélité LIME limite ici la portée de ses poids.

## Recommandations et limites

AP CV : logistique 0.384, XGBoost 0.427. Retenir le classement CV pour la démonstration ; préférer la logistique si sa perte de performance est acceptable face au besoin d'audit des coefficients. Valider prospectivement, fixer les coûts des faux positifs (sollicitations inutiles) et faux négatifs (occasions manquées), calibrer sur l'entraînement et auditer les groupes avant tout usage. Données anciennes, dépendances temporelles et clients répétés possibles, séparation aléatoire non prospective, petit budget de recherche et explications échantillonnées limitent la généralisation. Ne pas déduire des actions causales des attributions.

Source : Moro, S., Rita, P. et Cortez, P. (2014), Bank Marketing, UCI, DOI 10.24432/C5K306, CC BY 4.0. Résultats traçables : reports/experiment.json. Cahier des charges : PDF officiel, pages 1-4.